2025 商网智能问答 项目开发文档

项目介绍

基于各地市政府已有的政府文件、faq 问答等数据，利用 LLM 技术完成智能问答系统的升级迭代（需要支持多轮问答），具体可参照黄山市的智能问答（这个是科大讯飞做的）

https://www.huangshan.gov.cn/

目标功能（实现的效果、数据集）

数据源：政府公文数据（doc、pdf 等非结构化），部分 faq 数据，办事服务指南（半结构化数据，类似表格），部分新闻类性质数据。

数据总量：非结构化数据总量在 10000 条附近，数据量不多，但是覆盖面较杂

遇到过的问题：

1、**实现的效果要求：**数据源较为杂的情况下，去年用的召回方法效果不够稳定。用的 ES 文本 + 向量召回，向量基于 bge-base， rerank 是基于业务思维写的，没有上 bge 去做。目前资源够的情况下看可以整体优化
2、**内容解析要求**：部分文件的结构较为复杂，包含表格图片等数据，简单的解析方法无法处理部分数据。这里可以用 deepdoc 这种方法去拓展解析的能力
3、**政策文件版本管理要求**：政府数据存在说新老交替的情况，比如 23 年发的一个文 A， 24 年会少量修改后再发一次。目前的数据库里面没有这类的关系，去年给的解决方案是需要建立一个这样的关系（因为这种文的标题不一定就一样，从标题判断很容易遗漏），但是这个方案推行起来客户那边有困难，不知可有其他解决方案
4、**多轮问答**，目前是基于问题改写做的；
5、**拒绝回答能力**：敏感话题屏蔽，比如各种涉敏，涉政的东西，目前是从 prompt 里面处理的；

数据样例

https://xc.ahzwfw.gov.cn/

https://www.huangshan.gov.cn/site/tpl/4905?id=250723161039040&view=1

https://www.xuancheng.gov.cn/Service/show/4028e6a6901628f801902e718e2b6586/fd1f98f343dd4342818f1c16303950a1.html

项目时间规划

序号	名称	我方事项	责任人	商网事项	责任人	时间计划
1	第一周（第一阶段）	Embedding模型部署及API功能测试	[illegible]	2卡4090云服务到位， 用于模型部署测试（价格太贵可以1卡，但是效果跟后续情况差距较大，不是很建议） 最晚周三到位		
		Reranker模型部署及API功能测试	[illegible]			
		Deepseek部署及速度测试，推理加速功能测试	[illegible]	一套ES服务，用于存储预处理后的数据， 本地或者云服务都可以，如果是云服务的话就部署在CPU机器上		
		完成开发用LLM 模型部署及相应问答调用功能接口调试，具体包含如下： 1、文档总结能力API，用于在预处理的过程中提供相应支持，提升后续召回的准确度 2、问答生成API	[illegible]			
		数据处理功能部署，ES增删改查功能 完成数据预处理功能开发测试，同工程侧联调	[illegible]	数据处理接口对接		
		办事服务数据处理入库 12345数据处理入库				
2	第二周（第二阶段）	完成层次召回功能开发，召回效果测试	[illegible]	问答接口对接、联调， 可以支持初步问答测试		
		prompt构建、初步测试问答功能及效果	[illegible]	完成前端界面，可用于问答测试使用		
		政策文件处理优化入库，尽量支持表格等复杂数据处理（入库80%）	[illegible]	问答交互中，不同数据类型问答情况下的业务交互逻辑分析，可参照黄山		
		问答的合规性测试及规范性调整	[illegible]			
3	第三周（第三阶段）	政策文件相关问答功能测试及整体效果测试、数据处理方案优化	[illegible]	功能测试， 对于效果差的一些case提出反馈，同算法端一起判断case是否合理以及期望方向等一系列问题。		
		多轮问答功能实现及测试	[illegible]			
		召回效果及情况分析、相关召回算法优化	[illegible]			
4	第四周（第四阶段）	prompt调试及问答效果优化	[illegible]	协助完成最终测试，功能调整对接		
		市长之窗数据接入（尽量完成）	[illegible]			
		bad case原因分析及算法调整	[illegible]			
		政策文件全量入库（剩余20%）， 模拟测试数据更新情况下的效果及问答召回整体稳定性	[illegible]			

项目后端模块设计

模块名称	子模块名称	接口名称	功能
大模型	本地 DeepSeek 大模型调用	/v1/algo/llm	
	云端大模型调用		
算法模块 底层预训练模型	文本编码（SBERT）检索相似文档	/v1/algo/embeeding	
	文本重排序	/v1/algo/rerank	
	~~关键词提取~~	~~/v1/algo/keyword~~	
	~~文本分类~~	~~/v1/algo/classify~~	
	~~内容提取~~	~~/v1/algo/ocr~~	
数据模块 常规后端开发	插入文档	/v1/doc	
	更新文档 / 删除文档 / 获取文档	/v1/data/doc/{doc_id}	
	插入 faq	/v1/data/faq	
	更新 faq / 删除 faq / 获取 faq	/v1/data/doc/{faq_id}	
问答模块 业务逻辑	智能问答	/v1/biz/chat	
	删除对话 / 获取对话	/v1/biz/chat/{chat_id}	
	提问联想	/v1/biz/similar-question	
	常见问题	/v1/biz/common-question	
	历史对话记录	/v1/biz/history-chat	

项目开发过程

第一阶段：背景调研，厘清现状

去年，我们的团队基于 ES+ 向量召回为政府搭建了初版的问答系统，但运行一年后，客户反馈了一些核心痛点，这也是我们本次升级需要重点攻克的山头：

1. **召回效果不稳定**：数据源杂（公文、FAQ、办事指南、新闻），导致单纯的关键字（ES）和语义（向量）召回，在部分复杂问题上表现不佳，时好时坏。

2. **内容解析不彻底**：很多 PDF 文件内含复杂表格和排版，传统解析方法会丢失大量关键信息，直接影响了后续的知识库质量。
3. **政策版本管理混乱**：这是政府数据特有的“老大难”问题。新旧政策文件交替，但系统无法自动识别它们之间的关联，全靠人工标注，费时费力且容易遗漏。
4. **多轮问答体验生硬**：基于问题改写的方法，在对话轮次一多后，容易丢失上下文或误解用户意图。
5. **安全红线**：如何精准地拒绝回答敏感、涉政问题，是项目必须守住的底线。

第二阶段：技术选型与架构升级

- 我们保留了 ES 和向量召回（将 BGE 模型升级为更先进的版本）作为“初赛通道”，确保召回结果的广度和多样性。
- 核心改进在于引入了**专业的重排序模型**。我们不再使用简单的业务规则进行 rerank，而是训练了一个基于 BGE 的交叉编码器模型，让它专门学习文档与问题的相关度，对初召回的文档进行精准打分和重排。这一步极大地提升了 Top3 文档的准确率。
- 我们在答案生成环节做了特殊处理：当大模型在生成答案时，如果发现检索到的文档中，存在发布时间不同但内容高度相似或可能有关联的政策文件，它会在答案末尾主动提示用户：“此外，系统检测到可能存在相关政策更新，如[文件 B 标题]，发布于[日期]，建议您结合最新文件进行综合判断。”

第三阶段：模块化开发与集成

我们按照设计，将系统拆解为清晰的后端模块进行开发：

1. **大模型模块**：我们以本地部署的 DeepSeek 模型为核心，并预留了云端大模型的切换接口作为备份，保证了服务的可控性和灵活性。
2. **算法模块**：我们封装了文本编码、重排序、关键词提取、分类和 OCR 等核心算法能力，通过统一的 API 对外提供服务。特别是 `/v1/algo/rerank` 这个接口，成了我们检索效果的“胜负手”。
3. **数据模块**：我们开发了完善的文档和 FAQ 的增删改查接口，方便客户运营人员后续维护知识库。
4. **问答模块**：这是业务的集大成者。 `/v1/biz/chat` 接口整合了所有底层能力：它接收用户问题，调用检索、重排序，结合会话历史，最终交由大模型生成安全、准确、友善的答案。同时，我们还开发了“提问联想”、“常见问题”等辅助功能，提升用户体验。